

Daniela Abarca Sepulveda

Pregunta de análisis (FASE 2)

¿Por qué Spark pudo cargar el JSON aunque tiene estructuras anidadas?

Spark puede cargar archivos JSON con estructuras anidadas porque trabaja con el concepto de **Schema-on-Read**, lo que significa que no necesita una estructura fija antes de cargar los datos. Spark analiza el archivo al momento de leerlo e identifica automáticamente su estructura. Esto permite manejar datos semiestructurados, como JSON, sin generar errores, a diferencia de bases de datos tradicionales que requieren un esquema definido previamente.

Pregunta de reflexión (FASE 4)

¿Spark tardó mucho? ¿Qué pasaría si el archivo pesara 1 TB?

Spark normalmente no tarda mucho porque utiliza procesamiento distribuido y evaluación perezosa. Esto significa que Spark solo ejecuta las operaciones cuando se necesita un resultado final, optimizando el uso de recursos.

Si el archivo pesara 1 TB, Spark dividiría los datos en múltiples particiones y distribuiría el trabajo entre varios núcleos del procesador o incluso entre varios servidores. Primero procesaría los datos de forma paralela (Map) y después combinaría los resultados (Reduce), permitiendo analizar grandes volúmenes de información de manera eficiente.

Explicación del reto final

¿Por qué Spark crea varios archivos dentro de la carpeta Parquet?

Spark divide los datos en particiones para poder procesarlos y guardarlos de forma distribuida. Cada archivo representa una parte del conjunto total de datos. Esto permite mejorar la velocidad de lectura y escritura, además de facilitar el procesamiento paralelo en sistemas de Big Data.

La salida de la consulta SQL de los artistas top.

[14]:

```
spark.sql(query_top_artistas).show()
```

artista	total_reproducciones	horas_totales
Taylor Swift	7835	357.18
Drake	7812	358.21
BTS	7780	357.61